

Klasifikasi Jenis Sampah

UAS Praktikum Machine Learning

Kelompok 6

Achmad Atha Zayyan (2308107010033)

Muhammad Aidil Fitrah (2308107010035)



Dataset & Eksplorasi Data

- Overview dataset garbage classification
- Distribusi kelas & jumlah data
- Pembagian train / val / test



Arsitektur & Training

- 4 varian model CNN yang dibandingkan
- Konfigurasi training & augmentasi
- Perbandingan hasil evaluasi



Deployment & Robustness

- Konversi model ke format ONNX
- FastAPI backend + Render hosting
- Threshold & gap untuk deteksi *unknown*
- Demo web app *garbage classifier*



Refleksi

- Tantangan & solusi yang ditempuh
- Rekomendasi pengembangan
- Kesimpulan



Informasi Dataset

Sumber	Kaggle (<i>garbage-classification</i>)
Format	.jpg (semua kelas)
Resolusi	Bervariasi → <i>resize</i> 224×224
Total	1.987 gambar
Kelas	4 label (glass, metal, paper, plastic)

⚠ Imbalance: *Metal* sedikit (410), *Paper* banyak (594). Diatasi dengan **stratified split**.

Distribusi Per Kelas

Kelas	Jumlah	Proporsi
Glass	501	25.2%
Metal	410	20.6%
Paper	594	29.9%
Plastic	482	24.3%
Total	1.987	100%



Strategi Pembagian Data

Split	%	Jumlah	Fungsi
Train	80%	1.589	Pelatihan model
Validation	10%	199	Tuning hyper-params
Test	10%	199	Evaluasi akhir
Total		1.987	

✓ **Stratified Split** (`train_test_split`) menjaga proporsi kelas di train/val/test.

Pipeline Preprocessing

- ➔ Resize gambar ke 224×224 px
- ➔ Konversi ke array float32
- ➔ Batch size: 32

Augmentasi Data (Model 3)

Teknik	Parameter
Rotation	$\pm 15^\circ$
Zoom	10%
Width shift	10%
Height shift	10%
Horizontal flip	<i>enabled</i>
Brightness	[0.9, 1.1]
Fill mode	nearest

Train 1.589 gambar 80%

Validation 199 gambar 10%

Test 199 gambar 10%



Model 1

Basic CNN

3 Conv Blocks
32 → 64 → 128 filter
+ MaxPooling

Dense (128)
Dropout (0.5)
Softmax (4)

Tanpa BatchNorm
Tanpa Augmentasi

Model 2

Deep CNN + BN

4 Conv Blocks
32 → 64 → 128 → 256
+ BatchNorm tiap blok

Dense (256 + 128)
Dropout (0.5 + 0.3)
Softmax (4)

9.86 juta parameter
Tanpa Augmentasi

Model 3

Deep CNN + BN + Augmentasi

Arsitektur sama
seperti Model 2

9.86 juta parameter

Ditambah augmentasi:
rotasi, zoom, flip,
shift, brightness

Model 4 ★

MobileNetV2 Transfer Learning

ImageNet pretrained
Base frozen


GAP → Dense (128)
Dropout (0.5)
Softmax (4)

2.42 juta parameter
Trainable: 164.484

❗ Semua model dilatih dengan **Adam** (lr=0.001), **categorical_crossentropy**, callback **EarlyStopping** (patience=5) + **ReduceLROnPlateau**. GPU: 2× NVIDIA T4.



Arsitektur Model



82.91%

Test Accuracy


82.85%

F1-Score

Spesifikasi Teknis

Backbone	MobileNetV2 (ImageNet)
Input	224 × 224
Pooling	GlobalAveragePooling2D
Total Param	2.422.468 (9.24 MB)
Trainable	164.484 (642 KB)
Frozen	2.257.984 (8.61 MB)
Epochs	Maks 20 (EarlyStopping)
Batch Size	32
Optimizer	Adam (lr=0.001)

⚡ Transfer Learning: Bobot ImageNet mempercepat konvergensi dan meningkatkan performa pada dataset terbatas (<2k gambar).




Ringkasan Training

Epoch terbaik	Epoch 11
Best val acc	91.46%
LR reduksi	Ep. 8, 11, 13
Train acc akhir	98.51%
Callback	EarlyStopping (patience=5, best weights restored)

Observasi Kunci

- ✓ Val acc >78% sejak epoch 1 (pretrained)
- ✓ Konvergensi cepat (<5 epoch pertama)
- ⚠ Gap train-val: **overfitting tipis** di akhir
- ✓ ReduceLROnPlateau berhasil menstabilkan val acc



Tabel Evaluasi Lengkap


Model	Acc	Prec	Rec	F1
Basic CNN	61.3	64.1	61.3	60.9
Deep CNN+BN	59.3	64.4	59.3	59.1
Deep+BN+Aug	68.3	74.0	68.3	68.0
MobileNetV2	82.9	82.9	82.9	82.9

🏆 **MobileNetV2** unggul di semua metrik (Acc **82.9%**), selisih **+14.5%** dari model terbaik kedua.

📈 Model 2 (Deep CNN) lebih rendah dari Model 1, menunjukkan arsitektur lebih dalam tidak selalu lebih baik tanpa augmentasi.



Alur Konversi



```
$ python -m tf2onnx.convert
--saved-model saved_model
--output mobilenet.onnx
```

Mengapa ONNX?

- ✓ **Framework agnostic** — berjalan tanpa TensorFlow di production
- ✓ **Lebih ringan** — tidak perlu install TF (500MB+) di server
- ✓ **ONNX Runtime** jauh lebih cepat untuk inferensi CPU
- ✓ **Portabel** — kompatibel dengan berbagai platform deployment

Log Konversi

```
tf2onnx=1.17.0, opset 15
After optimization:
Transpose -120 (121→1)
Add -35 (64→29)
ONNX saved: mobilenet.onnx
```

✓ **Konversi berhasil tanpa error**



Masalah: *Closed-Set Classifier*

Model Softmax selalu menebak salah satu dari 4 kelas (misal input makanan/manusia). Tanpa penanaman khusus, model memberikan prediksi salah dengan confidence tinggi.

Solusi: Dua Lapis Filter

- 1. Confidence Threshold (0.70):** Jika $\text{max_prob} < 0.70 \Rightarrow \text{Unknown Object}$
- 2. Gap Threshold (0.20):** Jika selisih top-1 dan top-2 $< 0.20 \Rightarrow \text{Unknown Object}$

🛡 Kedua kondisi bersifat **OR**: jika salah satu terpenuhi, output dikategorikan sebagai "Unknown Object".


Implementasi di FastAPI

```
sorted_p = np.sort(probs)
gap = sorted_p[-1] - sorted_p[-2]

if confidence < 0.70 or gap < 0.20:
    label = "Unknown Object"
else:
    label = predicted_class
```

Contoh Kasus

Input	Conf	Gap	Output
Gelas bening	86%	78%	glass
Gambar mobil	45%	12%	Unknown
Foto makanan	61%	8%	Unknown
Botol plastik	79%	55%	plastic



</> Frontend

HTML + Vanilla JS + CSS
Fetch API (POST FormData)
Preview gambar real-time

Tabel probabilitas semua kelas

Backend (FastAPI)

Endpoint: `POST /predict`
`GET /classes`
`GET /health`

CORS enabled (all origins)

Hosting (Render)

Gratis tier
Auto-deploy dari Git
Python runtime

Uvicorn ASGI server



Struktur File

```
└─ model/
  └─ mobilenet.onnx      model
  └─ index.html          frontend
  └─ main.py             API
  └─ render.yaml         deploy
  └─ requirements.txt     deps
  └─ README.md           docs
```

```
# requirements.txt
fastapi
uvicorn
numpy
pillow
python-multipart
onnxruntime
```

Tech Stack Lengkap

Layer	Teknologi	Versi
Training	TensorFlow/Keras	2.19.0
Training	PyTorch + timm	2.10.0
GPU	NVIDIA Tesla T4	2×
Model fmt	ONNX + tf2onnx	1.17.0
Inference	ONNX Runtime	latest
Backend	FastAPI + Uvicorn	latest
Frontend	HTML / JS / CSS	Vanilla
Hosting	Render.com	free tier

🔗 API Endpoint:

<https://garbage-classifier-be.onrender.com/predict>

POST file gambar → output JSON berisi label, confidence, gap, reason, dan probabilities.



Tantangan	Deskripsi	Solusi
Custom CNN Underperform	Model 1 & 2 sulit konvergen dengan data <2k gambar (acc 59–61%)	Beralih ke transfer learning MobileNetV2 (acc 82.9%)
Class Imbalance	Metal (410) vs Paper (594) — selisih cukup signifikan	Stratified split untuk menjaga proporsi di semua subset
TF di Production	TF berukuran 500MB+, boros resource di server gratis	Konversi ke ONNX — hanya butuh onnxruntime (~10MB)
CORS Error	Frontend tidak bisa memanggil API karena kebijakan browser	Konfigurasi FastAPI CORSMiddleware (allow_origins=["*"])
OOD & Overfitting	Model menebak kelas sampah untuk gambar tidak relevan; gap train–test acc besar	Threshold 70% + Gap 20% untuk deteksi <i>Unknown</i> ; Dropout 0.5 + EarlyStopping



⬆ Peningkatan Model

- **Fine-tuning** lapisan atas MobileNetV2 (unfreeze sebagian) untuk akurasi lebih tinggi
- Tambah **augmentasi lebih agresif** (cutmix, mixup, random erasing)
- Coba backbone yang lebih kuat: **EfficientNetB0 / ResNet50**
- **Perbesar dataset** per kelas atau gunakan dataset publik tambahan
- Tambahkan kelas baru: *cardboard, trash, organic*

🦋 Peningkatan Deployment

- **Kalibrasi threshold** — tuning nilai confidence & gap secara empiris pada data OOD tervalidasi
- Tambahkan **Grad-CAM** visualization untuk menampilkan area yang “diperhatikan” model
- Deployment sebagai **PWA mobile app** agar bisa diakses di smartphone
- Tambah **riwayat prediksi** dan *feedback loop* dari pengguna
- **Kuantisasi ONNX** untuk inference lebih cepat di edge device



1. Membangun sistem klasifikasi sampah 4 kelas (*glass, metal, paper, plastic*) dengan **1.987 gambar**.
2. **MobileNetV2 (transfer learning)** terbaik dengan akurasi **82.91%** dan F1-score **82.85%** pada data test.
3. Transfer learning sangat efektif untuk dataset kecil, mempercepat konvergensi.
4. Model dikonversi ke **ONNX** dan di-deploy via FastAPI di Render.com untuk akses real-time.
5. Deteksi **unknown** menggunakan **confidence (70%)** dan **gap (20%)** threshold untuk data OOD.

Rangkuman Metrik

82.91%

Test Accuracy

82.85%

F1-Score

1.987

Total Data

4

Kelas Label

9.24 MB

Model Size

ONNX

Format Deploy

70%

Conf Thresh

20%

Gap Thresh



"AI sederhana pun bisa membantu pengelolaan sampah."



Terima Kasih

Pertanyaan & Diskusi